Spark

11/05/2018

Everton Osnei Cesario

Apresentação

- Everton Osnei Cesario
  - Sistemas de Informação / BI / Big Data / Mestrando IA – Saúde
  - Modelos Preditivos / KDD / Data Mining
- Desenvolvedor
  - Qlikview / MicroStrategy /C++/Java
- Professor Pós Positivo
  - Business Intelligence
  - Inteligência Artificial
  - Big Data
- Celepar
  - 8 anos - 2 Pentaho - 6 Qlikview / MicroStrategy
  - 2 Big Data – Analytics / IA
- Administração de ambientes
  - Dimensionamento e disponibilidade.
  - 4 Servidores Qlikview
  - Cluster 4 Servidores Big Data – HortonWorks
  - 2 Servidores Microstrategy
  - 2 Servidores Analytics – Weka/SPSS/Jupyter

Celepar

- Clientes
  - Secretarias
    - Fazenda, Educação, Justiça, Cultura, Segurança, Planejamento, Saúde, Identificação, Tribunal de Contas, Agricultura
  - Detran
  - Agência de Fomento
  - Portos
  - Bombeiros
- 19 Bases de dados Distintas, 486 Bi´s desenvolvidos e publicados
- Média de 6.000 acessos/mês

Agenda

- Aulas
  - 11/05 - Teórica
  - 12/05 - Teórica / Prática
  - 25/05 - Prática
  - 26/05 - Prática / Trabalho
- Trabalho

Agenda

- Oque é
- Características
- Arquitetura
- Terminologia
- Instalação e Configuração
  - Windows
- Rdd´s
- Transformações e Ações
- Funções
- SparkSQL
  - Hive
- Spark Streaming
- Anaconda + Jupyter Notebook

Objetivos

- Instalação e configuração do Spark + Anaconda + Jupyter Notebook
  - Windows
  - VM Virtualbox – Pronta
  - VM Cloudera 5.10 ou 5.5
    - Testar Spark – spark-shell
- Wordcount
  - Scala
  - Python
  - Eclipse - Scala e Java
- Mtos exercícios
- Trabalho

Quem somos?

- Nome?
- Formação?
- Onde trabalha?
  - Possuí sistema de BI ou BigData?
- Oque faz?
  - Como gostaria que fosse feito?
  - Resultados?
- Hobbies
- Oque mais achar necessário =)

Oque é?

- Big Data
- Hadoop
  - Maquinas baratas
  - Premissa que máquinas darão problemas
  - Mover código entre maquinas é mto mais eficiente que mover dados.
  - Desenvolvimento focado no problema
  - cluster manager, distributed compute engine, distributed file system
  - Yarn, MapReduce e HDFS
- GFS
- HDFS
- Nosql
- Business Intelligence
- Inteligência Artificial

Spark – Oque é?

- Mecanismo de computação de uso geral para **processamento de dados em larga escala**.
- "uma estrutura de computação em cluster na memória para processar e analisar grandes quantidades de dados."
- Open Source*
- AMPLab doação para Apache
- Oferece uma camada de abstração de dados
  - Resilient Distributed Datasets – RDD
  - Analise de dados em paralelo
- Alternativa para o Hadoop MapReduce

Spark – Oque é?

- 100x Faster*******
- Escrito em Scala/Java
- Fornece Api´s – Scala, Java, Python e R

Características

- Fácil Uso;
  - Desenvolver uma aplicação distribuída com o Spark é mais facil que desenvolver uma rotina de MapReduce;
- Fornece API`s prontas
- Mais Rápido que as rotinas de MapReduce
  - Permite processamento em memória
    - 100x mais rapido se o volume de dados couber na memória, senão 10x
- Directed Acyclic Graph (DAG)
- Uso de Propósito Geral
  - Fornece uma plataforma integrada de diferentes tipos de Jobs

Características

- Escalável
- Tolerante à falhas
  - Pode ser que baixe a performance, porém o processo nao para.
  - Não existe a necessidade de se preocupar com as falhas.

Arquitetura

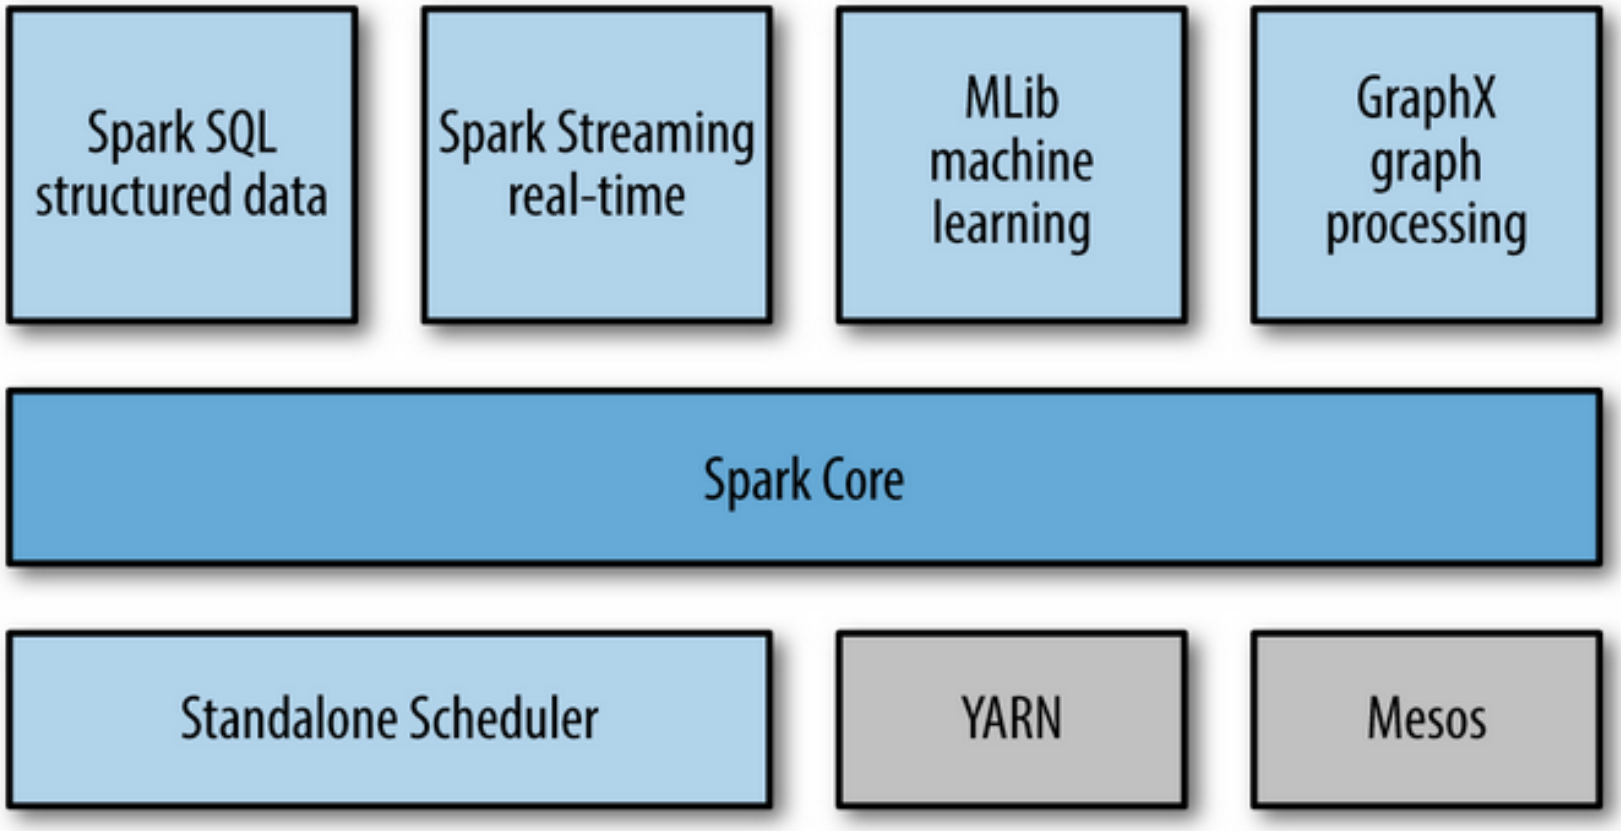

Arquitetura

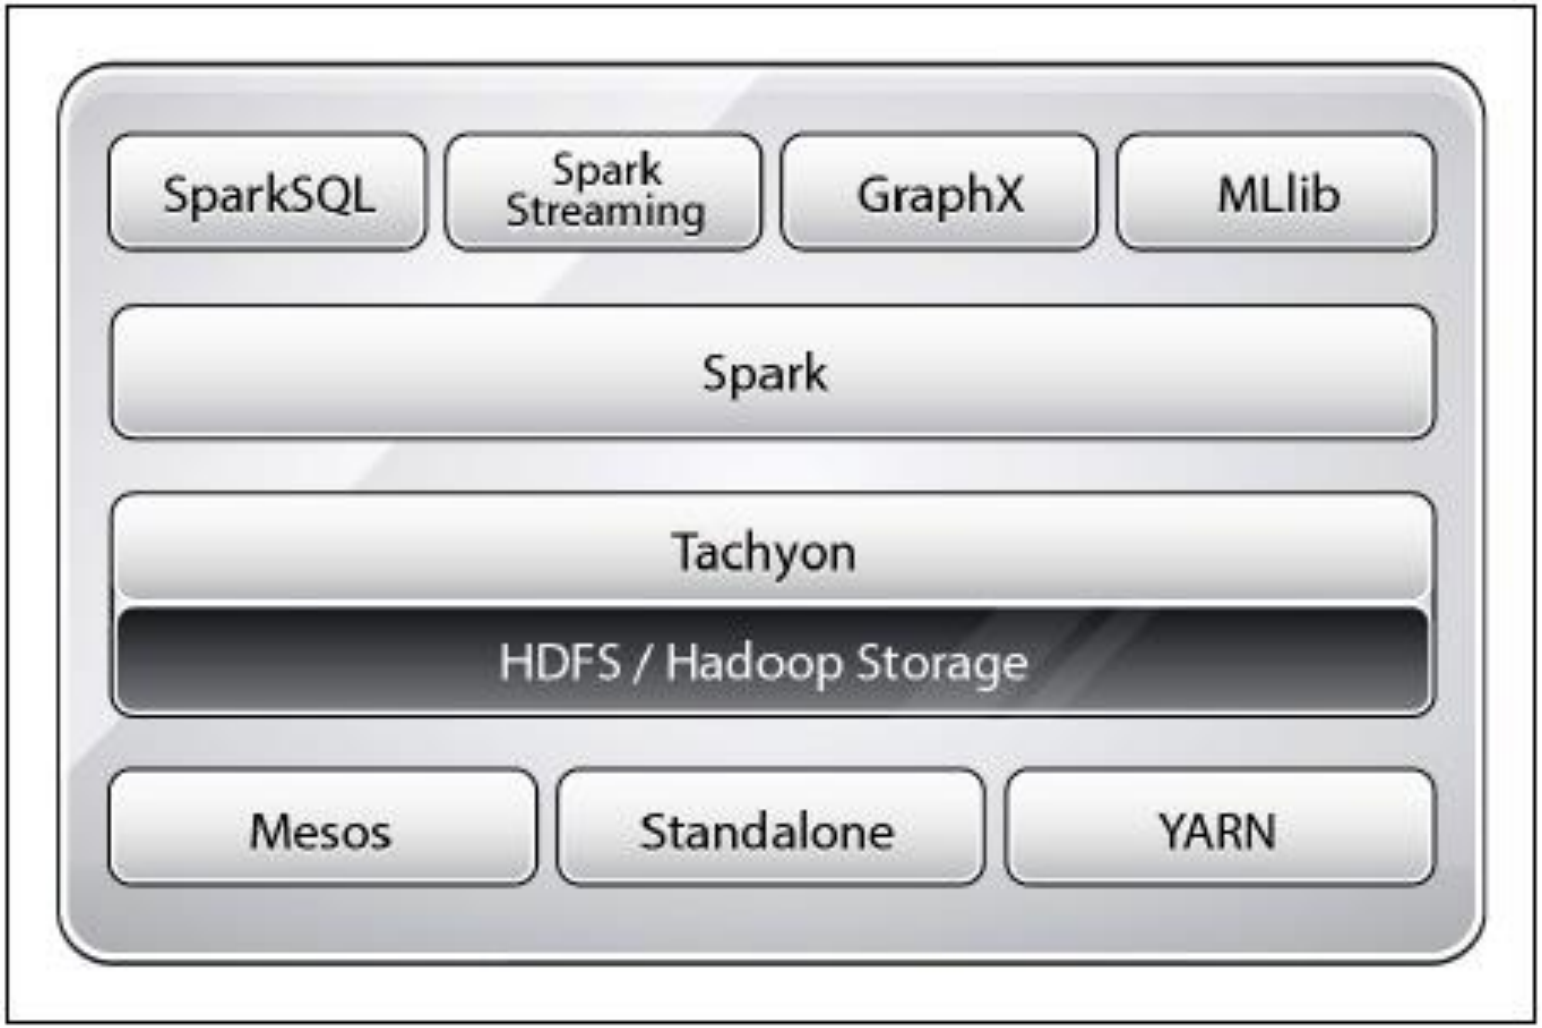

Arquitetura

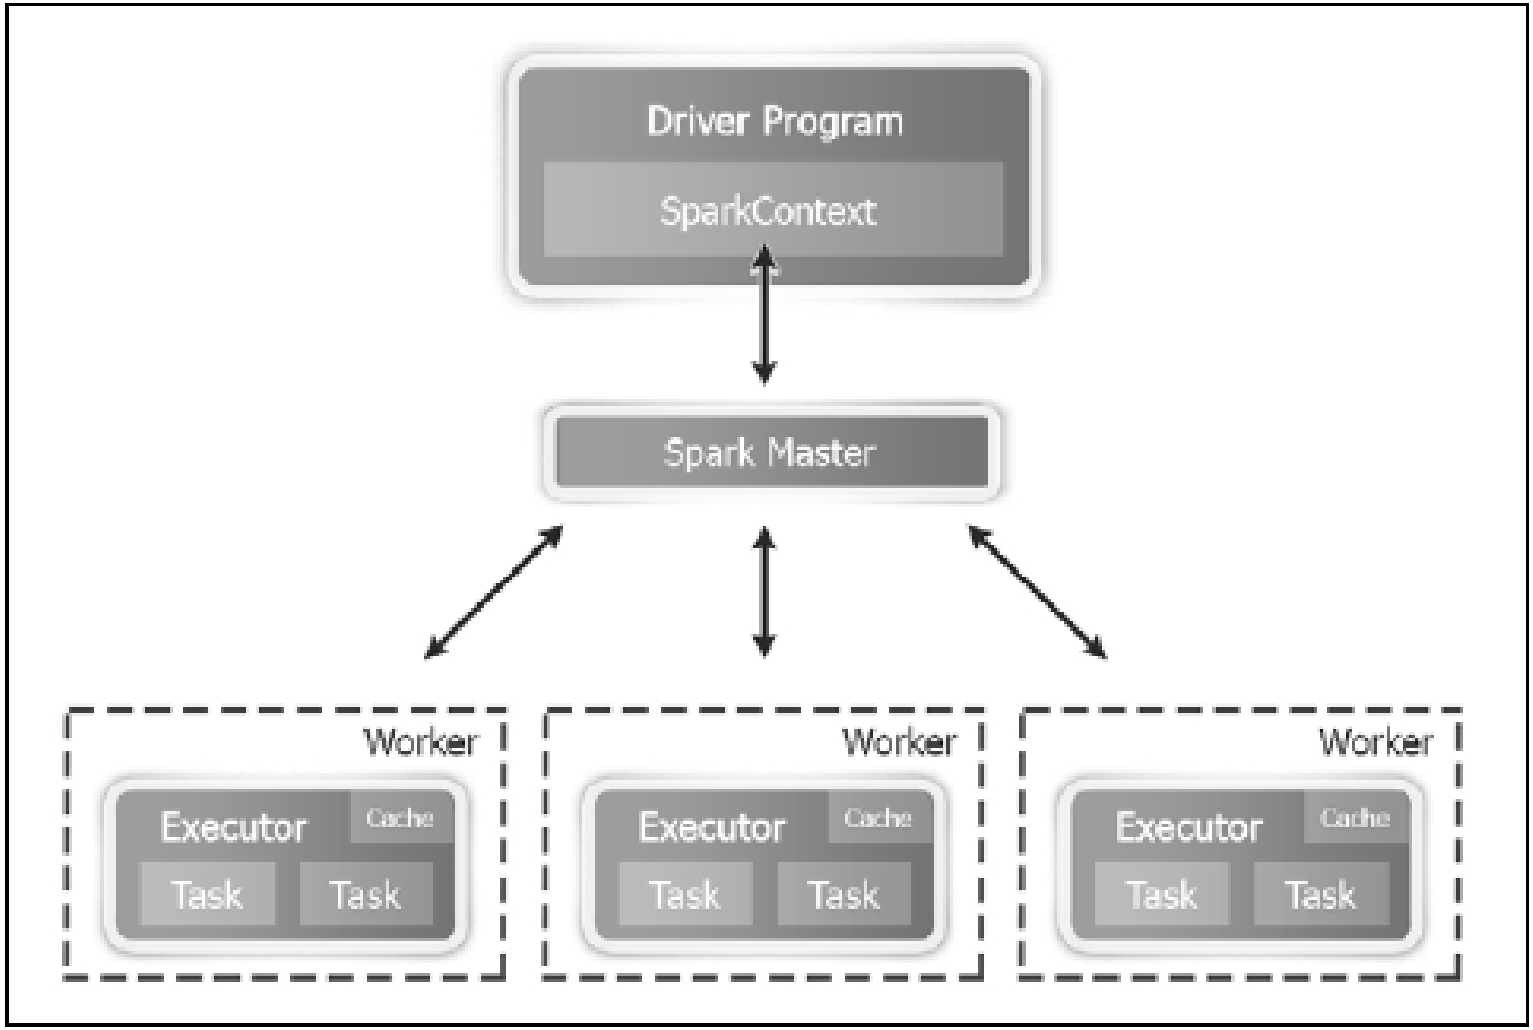

Arquitetura

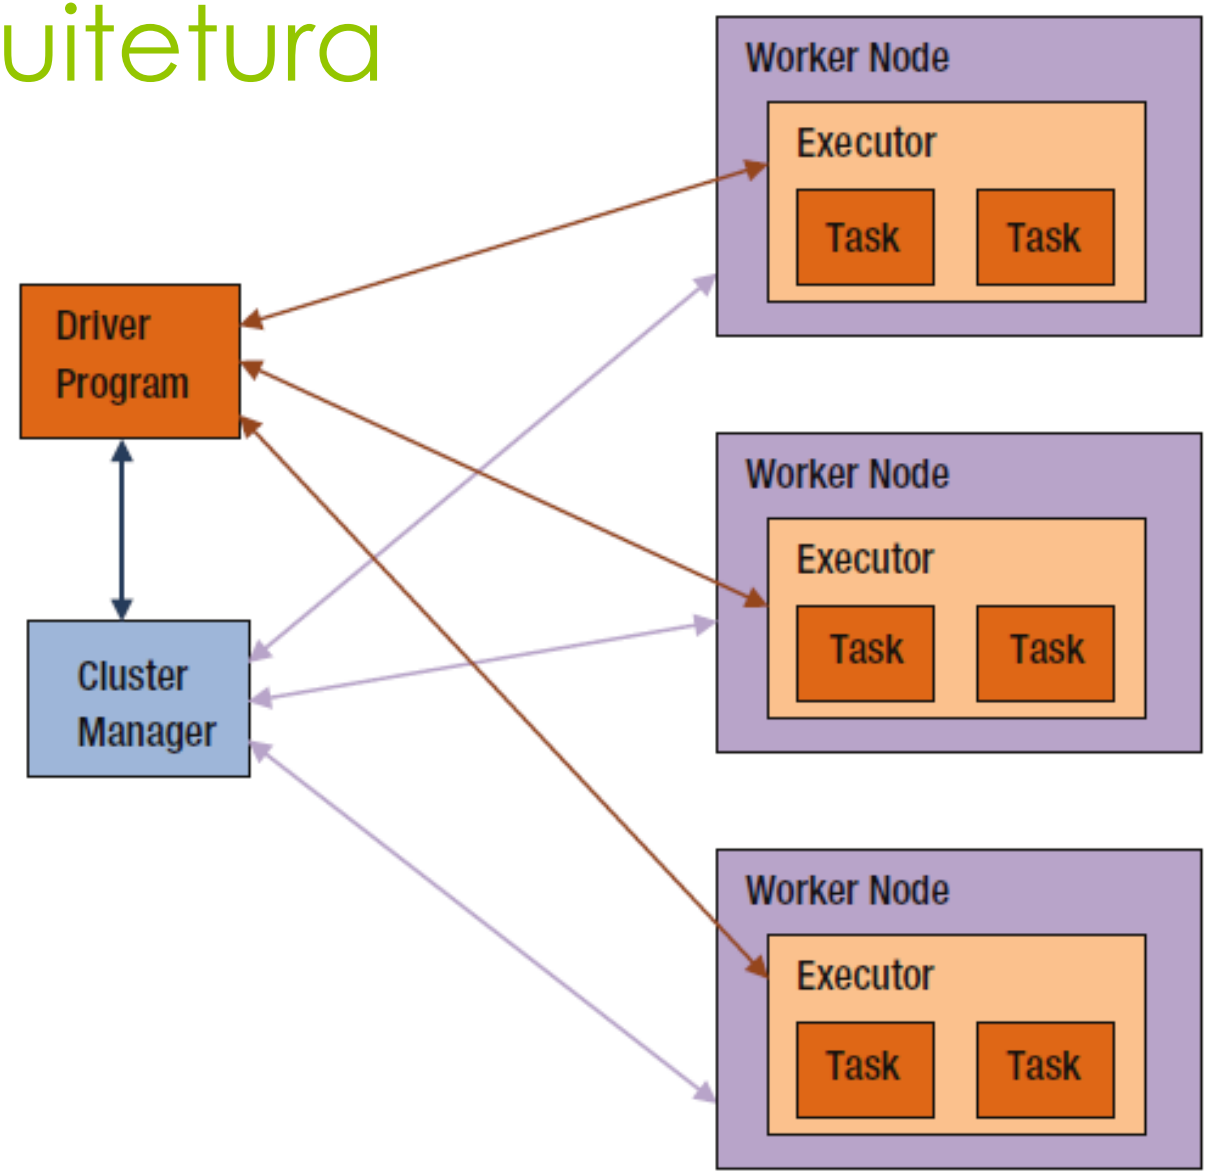

Arquitetura

- **Driver Program**
  - É um aplicativo que usa o Spark como uma biblioteca. Ele fornece o código de processamento de dados que o Spark executa nos nós (Worker).
  - O Driver Program pode iniciar um ou mais trabalhos em um cluster.

Arquitetura

- **Cluster Manager**
  - O Spark usa um gerenciador de cluster para **receber os recursos de cluster** para executar um job.
  - Fornece um agendamento de baixo nível dos recursos do cluster através das aplicações.
  - Permite que vários aplicativos compartilhem recursos de cluster e executem as tarefas nos mesmos nós de trabalho (Workers).
  - O Spark atualmente suporta três gerenciadores de cluster: Standalone, Mesos e YARN.
  - Mesos e YARN permitem que você execute aplicativos Spark e Hadoop simultaneamente nos mesmos nós de trabalho.

Arquitetura

- **Workers**
  - Fornece recursos de CPU, memória e armazenamento para o aplicativo.
  - Responsáveis por tornar uma aplicação em um processo distribuído no Cluster.
- **Executors**
  - O executor é o processo JVM (Java Virtual Machine) que o Spark cria em cada worker para executar um aplicativo.
  - Executa o código do aplicativo simultaneamente em várias threads.
  - Também pode armazenar dados em cache na memória ou no disco.
  - Um executor tem o mesmo tempo de vida que o aplicativo para o qual ele é criado. Quando um aplicativo termina, todos os executores criados para ele também terminam.

Arquitetura

- **Tasks**
  - A task é a menor unidade de trabalho que o Spark envia para um executor.
  - Ele é executado por um thread em um executor em um nó de trabalho(workers).
  - Cada tarefa executa alguns cálculos para retornar um resultado ao driver program ou particiona sua saída para shuffle.
  - O Spark cria uma task por partição de dados.
  - Um executor executa uma ou mais tarefas simultaneamente.
  - Quantidade de paralelismo é determinado pelo número de partições. Mais partições significam mais task´s processando dados em paralelo.

Terminologia

- **Shuffle**
  - O shuffle redistribui dados entre um cluster de nós.
  - É uma operação cara porque envolve a movimentação de dados através de uma rede.
  - Note que oque um shuffle faz não é redistribuir dados aleatoriamente;
  - Ele agrupa os conjuntos de dados em intervalos com base em alguns critérios.
  - Cada conjunto de dados forma uma nova partição

Terminologia

- **Job**
  - Um job é um conjunto de cálculos que o Spark executa para retornar resultados para um program driver.
  - Essencialmente, é uma execução de um algoritmo de processamento de dados em um cluster.
  - Um aplicativo pode iniciar vários jobs.

Terminologia

- **Stage**
  - É uma coleção de tasks.
  - O Spark divide um trabalho em um DAG de estágios.
  - Um stage pode depender de outro.
  - Por exemplo, um trabalho pode ser dividido em dois estágios, estágio 0 e estágio 1, em que o estágio 1 não pode começar até que o estágio 0 seja concluído.
  - Spark agrupa as task´s em stages usando limites do shuffle.
  - Tasks que não exigem um shuffle são agrupados no mesmo stage. Uma tarefa que requer que seus dados de entrada sejam embaralhados começa um novo estágio.

Ta e dae???

- Quando um aplicativo é executado, o Spark se conecta a um **cluster manager** e adquire **executors** nos **worker´s**.
- A aplicação envia o algoritmo de processamento de dados como um **job**.
- O Spark divide um trabalho em **stages** gerando um gráfico acíclico direcionado (DAG - directed acyclic graph) .
- Após, ele agenda a execução desses stages nos executors usando um planejador de baixo nível fornecido pelo cluster manager.
- Enfim os executors executam as tarefas enviadas pelo Spark em paralelo.

Ta e dae 2???

- Cada aplicativo obtém seu próprio conjunto de executores nos nós do worker.
- Este design fornece alguns benefícios.
  - Primeiro, as tasks de diferentes aplicativos **são isoladas umas das outras**, uma vez que elas são executadas em diferentes processos da JVM. Uma taks com mal funcionamento não pode travar outro aplicativo.
  - Segundo, agendamento de tarefas torna-se mais fácil porque o spark precisa agendar as tarefas pertencentes a apenas um aplicativo de cada vez. Ele não precisa lidar com as complexidades das tarefas de agendamento a partir de vários aplicativos em execução simultaneamente.

Hummmm!!!!

- No entanto, esse design também tem uma desvantagem.
- Como os aplicativos são executados em processos separados da JVM, **eles nao conseguem compartilhar dados com facilidade**.
- Mesmo que eles possam estar em execução nos mesmos nós de trabalho, eles não podem compartilhar dados sem gravá-lo em disco.
- Lembrando que escrever e ler dados do disco são operações caros.
- Portanto, os aplicativos que compartilham dados por meio do disco terão problemas de desempenho.

Instalação e Configuração

Spark Context

- SparkContext é uma classe definida na biblioteca sendo o principal ponto de entrada para uso das bibliotecas Spark.
- Ele representa uma conexão com um cluster Spark.
- Também é necessário para criar outros objetos importantes fornecidos pela API Spark.
- Um aplicativo deve criar uma instância da classe SparkContext.
- Normalmente um aplicativo pode ter apenas uma instância ativa do SparkContext.
- Para criar outra instância, primeiro deve parar a instância ativa.
- A classe SparkContext fornece vários construtores. O mais simples não aceita argumentos.

RDD

- Resilient Distributed Datasets
- O RDD representa uma coleção de elementos de dados particionados que podem ser operados em paralelo em diferentes nós do cluster.
- É o mecanismo primário de abstração, definido como uma classe abstrata na biblioteca Spark.
- Conceitualmente, o RDD é semelhante a uma coleção de dados, exceto pelo fato de representar um conjunto de dados distribuídos e suportar operações do tipo **lazy**.
- Quando um arquivo é lido usando o método textFile do SparkContext, o Spark não lê imediatamente o arquivo do disco. Da mesma forma, as transformações RDD, que retornam um novo RDD são computadas.

Lazy

- O Spark faz apenas uma anotação de como um RDD foi criado e as transformações aplicadas a ele

Ele usa essas informações para construir ou reconstruir um RDD quando necessário.

Aplicativos Spark

- Imutável – Uma vez criado, não pode ser modificado no local. Basicamente, um operação que modifica um RDD retorna um novo RDD.
- Os aplicativos do Spark processam dados usando os métodos definidos na classe RDD ou classes derivadas dele. Esses **métodos** também são conhecidos como **operações**.
- Processamento independe do volume de dados
- Processamento independe se é local ou distribuído
- Podem ser categorizadas de duas maneiras, **Transformação e Ação.**
  - Transformação cria um novo RDD
  - Ação retorna um valor para o Manager Driver

Transformações e Ações

- Transformações
  - Retornam um novo RDD baseado no original. API do Spark incluem map (), filter (), sample () e Union().
- Ações
  - Este tipo de operação retorna um valor baseado em algum tipo de processamento, sendo executada em um RDD. As ações disponíveis através da API Spark incluem reduce (), count (), first () e foreach ().

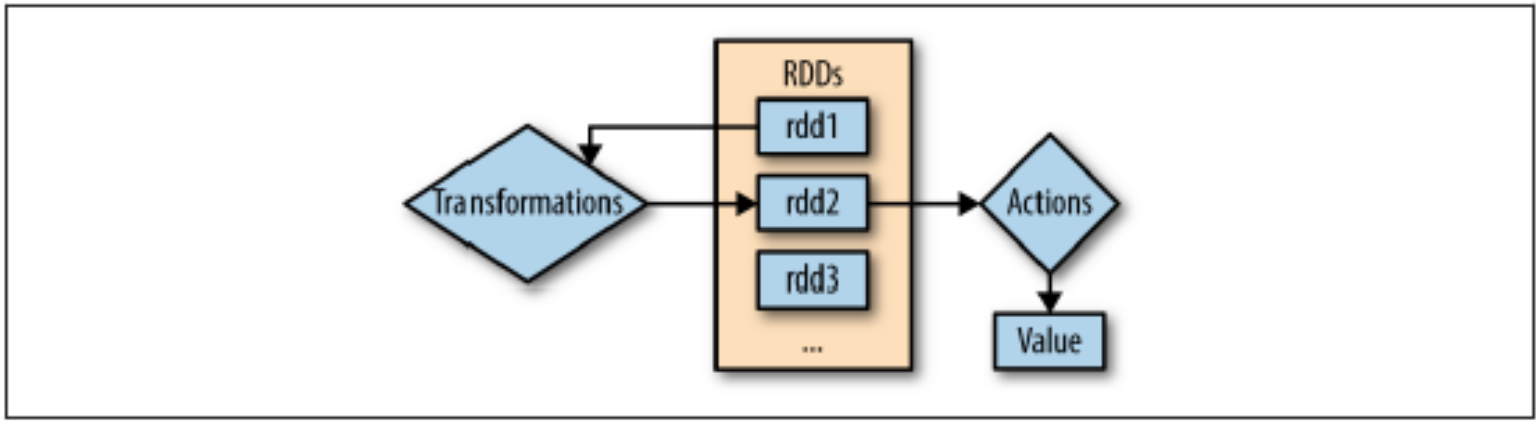

Spark-shell

- Spark-shell
- :help
- :quit
- :paste
  - Ctrl-D

- val xs = (1 to 1000).toList
- val xsRdd = sc.parallelize(xs)
- val evenRdd = xsRdd.filter{ _ % 2 == 0}
- val count = evenRdd.count
- val first = evenRdd.first

Transformações

- val xs = (1 to 10000).toList
- val rdd = sc.parallelize(xs)

- Leitura de um arquivo
  - val rdd = sc.textFile("C:/Dados/movies.txt")
  - rdd.collect().foreach(println)
- HDFS
- val rdd = sc.textFile("hdfs://namenode:9000/path/to/directory/*.gz")

- val rdd = sc.wholeTextFiles("path/to/my-data/*.txt")

Transformações

- map
  - val rdd = sc.textFile("C:/Dados/movies.txt")
  - val lengths = rdd map { l => l.length}
  - lengths.collect().foreach(println)
  - val lengths = rdd.map(w => (w,1))

- Filter
  - val rdd = sc.textFile("C:/Dados/movies.txt")
  - val lines = rdd filter { l => l.length < 27}
  - val one= rdd filter { l => l.contains("One")}
  - val year= rdd filter { l => l.contains("1993")}

Transformações

- FlatMap
  - val rdd = sc.textFile("C:/Dados/movies.txt")
  - val words = rdd.flatMap { l => l.split(",")}
  - val wordsf = rdd.flatMap(_.split("\\W+"))
  - val wordsMap = wordsf.map(w => (w,1))

- reduceByKey
  - val words = rdd flatMap {line => line.split(" ")}
  - val wordPairs = words map { word => (word, 1)}
  - val wordCounts = wordPairs.reduceByKey(_ + _)
- Sort
  - sortByKey(true)
  - sortBy(_._2, false)

Transformações

- Union
  - val rdd = sc.textFile("C:/Dados/movies.txt")
  - val rdd2 = sc.textFile("C:/Dados/movies2.txt")
  - val linesFromBothFiles = rdd.union(rdd2)
- Intersection
  - val linesPresentInBothFiles = rdd.intersection(rdd2)
- Subtract
  - val linesInFile1Only = rdd.subtract(rdd2)
- Distinct
  - val uniqueNumbers = rdd2.distinct

Transformações

Function name	Purpose	Example	Result
`map()`	Apply a function to each element in the RDD and return an RDD of the result.	`rdd.map(x => x + 1)`	`{2, 3, 4, 4}`
`flatMap()`	Apply a function to each element in the RDD and return an RDD of the contents of the iterators returned. Often used to extract words.	`rdd.flatMap(x => x.to(3))`	`{1, 2, 3, 2, 3, 3, 3}`
`filter()`	Return an RDD consisting of only elements that pass the condition passed to `filter()`.	`rdd.filter(x => x != 1)`	`{2, 3, 3}`
`distinct()`	Remove duplicates.	`rdd.distinct()`	`{1, 2, 3}`
`sample(withReplacement, fraction, [seed])`	Sample an RDD, with or without replacement.	`rdd.sample(false, 0.5)`	Nondeterministic

Function name	Purpose	Example	Result
`union()`	Produce an RDD containing elements from both RDDs.	`rdd.union(other)`	`{1, 2, 3, 3, 4, 5}`
`intersection()`	RDD containing only elements found in both RDDs.	`rdd.intersection(other)`	`{3}`
`subtract()`	Remove the contents of one RDD (e.g., remove training data).	`rdd.subtract(other)`	`{1, 2}`
`cartesian()`	Cartesian product with the other RDD.	`rdd.cartesian(other)`	`{(1, 3), (1, 4), … (3,5)}`

Exercicio 1

- Ler da pasta Dados\E1\texto.txt
- Identificar quais palavras mais ocorrem no texto
  - Quebrar o texto em um array
  - atribuir o valor 1 para cada item do array
  - Agrupar por chave
  - Ordenar
  - Ordenar de novo
  - Serializar os resultados

Ações

- Ações são métodos RDD que retornam um valor para o Driver Manager.

- Collect****
  - val rdd = sc.parallelize((1 to 10000).toList)
  - val filteredRdd = rdd filter { x => (x % 1000) == 0 }
  - val filterResult = filteredRdd.collect
- Count
  - val rdd = sc.parallelize((1 to 10000).toList)
  - val total = rdd.count
- CountByValue
  - val rdd = sc.parallelize(List(1, 2, 3, 4, 1, 2, 3, 1, 2, 1))
  - val counts = rdd.countByValue

Ações

- first
  - val rdd = sc.parallelize(List(10, 5, 3, 1))
  - val firstElement = rdd.first
- max
  - val rdd = sc.parallelize(List(2, 5, 3, 1))
  - val maxElement = rdd.max
- min
  - val rdd = sc.parallelize(List(2, 5, 3, 1))
  - val minElement = rdd.min
- top
  - val rdd = sc.parallelize(List(2, 5, 3, 1, 50, 100))
  - val largest3 = rdd.top(3)

Ações

- mean
  - val numbersRdd = sc.parallelize(List(2, 5, 3, 1))
  - val mean = numbersRdd.mean
- stdev
  - val numbersRdd = sc.parallelize(List(2, 5, 3, 1))
  - val stdev = numbersRdd.stdev
- sum
  - val numbersRdd = sc.parallelize(List(2, 5, 3, 1))
  - val sum = numbersRdd.sum
- variance
  - val numbersRdd = sc.parallelize(List(2, 5, 3, 1))
  - val variance = numbersRdd.variance

Ações

- Salvando os resultados
  - val numbersRdd = sc.parallelize((1 to 10000).toList)
  - val filteredRdd = numbersRdd filter { x => x % 1000 == 0}
  - filteredRdd.saveAsTextFile("c:/Dados/output")

Ações

Function name	Purpose	Example	Result
`collect()`	Return all elements from the RDD.	`rdd.collect()`	`{1, 2, 3, 3}`
`count()`	Number of elements in the RDD.	`rdd.count()`	`4`

`countByValue()`	Number of times each element occurs in the RDD.	`rdd.countByValue()`	`{(1, 1),`
			`(2, 1),`
			`(3, 2)}`

Ações

`take(num)`	Return num elements from the RDD.	`rdd.take(2)`	`{1, 2}`
`top(num)`	Return the top num elements the RDD.	`rdd.top(2)`	`{3, 3}`
`takeOrdered(num)(ordering)`	Return num elements based on provided ordering.	`rdd.takeOrdered(2)(myOrdering)`	`{3, 3}`
`takeSample(withReplacement, num, [seed])`	Return num elements at random.	`rdd.takeSample(false, 1)`	Nondeterministic
`reduce(func)`	Combine the elements of the RDD together in parallel (e.g., sum).	`rdd.reduce((x, y) => x + y)`	9
`fold(zero)(func)`	Same as `reduce()` but with the provided zero value.	`rdd.fold(0)((x, y) => x + y)`	9
`aggregate(zeroValue)(seqOp, combOp)`	Similar to `reduce()` but used to return a different type.	`rdd.aggregate((0, 0))((x, y) => (x._1 + y, x._2 + 1), (x, y) => (x._1 + y._1, x._2 + y._2))`	`(9, 4)`
`foreach(func)`	Apply the provided function to each element of the RDD.	`rdd.foreach(func)`	Nothing

Funções

- Sintaxe

```
def functionName ([list of parameters]) : [return type] = {
  function body
  return [expr]
}
```

- :paste

```
def addInt( a:Int, b:Int ) : Int = {
    var sum:Int = 0
    sum = a + b
    return sum
  }
```

- Ctrl+d
- addInt(1,2)

Spark Jobs

- Um Job é um conjunto de cálculos que o Spark realiza para retornar os resultados de uma Action a um Manage Driver. Um aplicativo pode iniciar um ou mais Jobs.
- Ele lança um Job chamando uma Action de um RDD. Portanto,uma Action aciona uma Job.
- Se uma ação é chamada para um RDD que não está em cache ou um descendente de outro RDD, o Job começa com a leitura de dados de um sistema de armazenamento.
- No entanto, se uma ação for solicitada um RDD armazenado em cache ou um descendente de um RDD em cache, um job começa a partir do ponto em que o RDD ou seu ancestral RDD foi armazenado em cache.
- Em seguida, o Spark aplica as transformações necessárias para criar o RDD cuja ação método foi chamado.
- Finalmente, executa os cálculos especificados pela ação.
- Um Job é concluído quando um resultado é retornado para um Manage Driver.
- Quando um aplicativo chama uma Action RDD, o Spark cria um DAG de Stages de tarefas.
- Agrupa tarefas em Stages usando limites de shuffle.
- Tarefas que não exigem shuffle são agrupadas no mesmo Stage.
- Uma tarefa que requer que seus dados de entrada sejam embaralhados começa um novo Stage.
- Um Stage pode ter uma ou mais tarefas. O Spark envia tarefas para os executores, que executam as tarefas em paralelo.
- As tarefas são agendadas nos nós com base na localidade dos dados. Se um nó falhar durante o Job em uma tarefa, o Spark reenviará tarefa para outro nó.

Exercicio 2

- Ler da pasta Dados\E2\logs.txt
- Passar todas palavras para minúsculas
- Pegar apenas as linhas que contém a palavra “erro”
- Pegar apenas as linhas que iniciam com a palavra “erro”
  - val errorLogs = logs.filter{_.split("\\s+")(0) }
- Salvar os resultados

Pratica Movies

- val rawLogs = sc.textFile("c:/Dados/movies.txt")
- val lengths = rawLogs.map{line => line.size}
- val maxLen = lengths.reduce{ (a, b) => if (a > b) a else b }
- Qual seria a outra maneira de conseguir o valor máximo do array?
- val wordCounts = rawLogs map {line => line.split("""\s+""").size}
- ll.saveAsTextFile("c:/Dados/movielogs")

Exercício 3

- Utilizando as informações da Pasta Dados/E2/registrosPlacas.txt, levantar as seguintes informações:
  - Preparar os dados
  - Identificar o veículo que tem mais registros
  - Identificar qual veículo teve a maior velocidade
  - Identificar qual veículo teve a maior velocidade média

Spark SQL

- Um dos principais motivos do Spark se tornar popular
- Existem muito mais pessoas que sabem Sql do que Spark, Scala etc
- Ajuda a criar e executar programas Spark mais rapidamente. Ele permite que os desenvolvedores escrevam **menos código**, que o **programa leia menos dados** e deixe o otimizador do **Catalyst** todo o trabalho pesado.

- Spark Sql é uma biblioteca que roda sobre o Spark, provendo uma camada abstrata para processamento de dados estruturados, nosql...
- Fornece integração com as funções mais conhecidas, **como filtros, agregações, seleções de colunas, joins etc**

- O Spark Sql pode ser utilizada como uma biblioteca para processamento em Scala, Java, Python ou R

- Os formatos de arquivos suportados pelo Spark SQL incluem CSV, JSON, Parquet, ORC e Avro.
- Bancos com conectores JDBC, entre eles:
- PostgreSQL, MySQL, H2, Oracle, DB2, MS SQL Server, HBase,
- Cassandra, Elasticsearch, Druid, e outros NoSQL

Spark SQL

- Integração com o Hive
  - Funciona com ou sem o Hive
- Armazenamento Colunar – Não existe a necessidade de ler todas as colunas.
- Caching In Memory
  - Compressão de dados
- Skip Rows – Faz uso do Statistics dos Gerenciadores de BD para nao ler informações desnecessárias
- Predicate Pushdown – Objetivo de de reduzir o I/O, aplica filtros e se possivel utiliza indices nativos do BD
- Query Optimization – Realiza otimização das queries antes de executa-las
  - Catalyst – Separa a query em 4 etapas
    - Analise
    - Otimização Lógica
    - Planjeamento Físico
    - Geração de Código

Spark SQL

Hive – Conversão de queries SQL em MapReduce

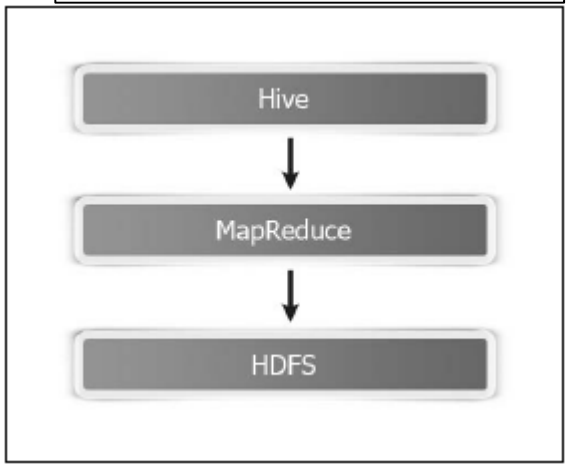

O Shark substituiu a parte MapReduce pelo Spark, mantendo a maior parte da base de código.

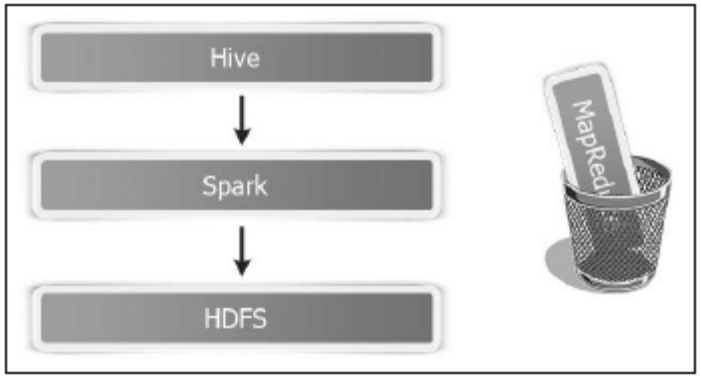

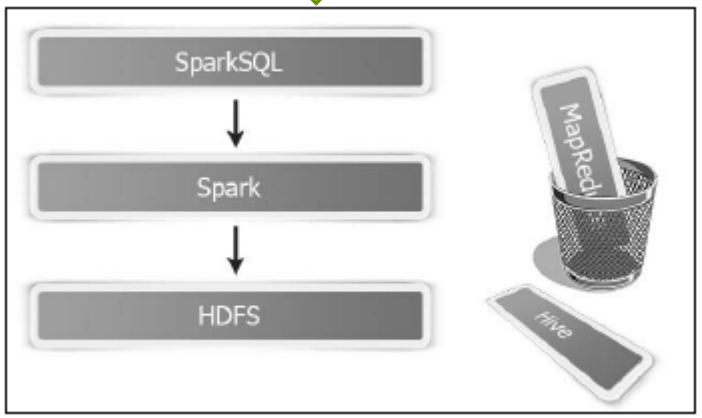

Inicialmente, funcionou bem, mas muito em breve, os desenvolvedores do Spark atingiram os limites e não conseguiram otimizar. Finalmente, eles decidiram escrever o SQL Engine do zero e que deu origem ao Spark SQL.

Spark SQL

- Spark Sql compila partes da query diretamente em bytecode Java, utilizando Scala(AST – Abstract Syntax Tree)
- Possibilidade de escrever queries em qq linguagem, o spark irá contruir um plano otimizado.
- O código gerado, normalmente, é mais rapido do que os criados/Tunados manualmente em Scala, Java ou Python
- *One of the benefits of code generation is that you can write a Spark SQL application in any supported*

  language without worrying about performance. ***For example, Python applications generally run slower than Java or Scala applications. However, a Spark SQL application written in Python will process data as fast as one written in Scala.***

SchemaRdd

- Tanto o carregamento de dados quanto a execução de consultas retornam SchemaRDDs. Os SchemaRDDs são semelhantes as tabelas em um banco de dados tradicional.
- Superficialmente, um SchemaRDD é um RDD composto de linhas de objetos com informações adicionais do esquema e dos tipos em cada coluna.
- Uma observação importante: em futuras versões do Spark, o nome SchemaRDD = DataFrame.
- Os SchemaRDDs também são RDDs regulares, para que você possa operá-los usando o RDD existente transformações como map () e filter (). No entanto, eles fornecem várias capacidades.
- possibilidade de salvar qualquer SchemaRDD como uma tabela temporária

Spark SQL

- Comparando os DataFrames com os RDDs.
- Um RDD é uma coleção de objetos sem ideia sobre o formato dos dados.
- Os DataFrames têm um esquema associado com eles, sendo assim, também podemos olhar para DataFrames como RDDs com o esquema adicionado a eles.
- Até o Spark 1.2, havia um artefato chamado SchemaRDD, que agora evoluiu para DataFrame. Eles fornecem funcionalidades muito mais ricas do que os SchemaRDDs.

Spark SQL

Spark SQL/HiveQL type	Scala type	Java type	Python
TINYINT	Byte	Byte/byte	int/long (in range of –128 to 127)
SMALLINT	Short	Short/short	int/long (in range of –32768 to 32767)
INT	Int	Int/int	int or long
BIGINT	Long	Long/long	long
FLOAT	Float	Float/float	float
DOUBLE	Double	Double/double	float
DECIMAL	Scala.math.BigDecimal	Java.math.BigDecimal	decimal.Decimal
STRING	String	String	string
BINARY	Array[Byte]	byte[]	bytearray
BOOLEAN	Boolean	Boolean/boolean	bool
TIMESTAMP	java.sql.TimeStamp	java.sql.TimeStamp	datetime.datetime
ARRAY<DATA_TYPE>	Seq	List	list, tuple, or array
MAP<KEY_TYPE,	Map	Map	dict

Spark SQL - Pratica

- Utilizando os dados do arquivo movies.txt
- val hc = new org.apache.spark.sql.hive.HiveContext(sc)

- hc.sql("create table if not exists movie(cod int, name string, year int, note float, views int) row format delimited fields terminated by ',"")

- hc.sql("load data local inpath \"c:/Dados/movies.txt\" into table movie")
- val mov = hc.sql("from movie select name,year,views")

- val mov = hc.sql("select * from movie where year=1993").collect().foreach(println)

Exercício 3.1

- Utilizando as informações da Pasta Dados/E2, levantar as seguintes informações:
  - Tratar o arquivo
  - Identificar o veículo que tem mais registros
  - Identificar qual veículo teve a maior velocidade
  - Identificar qual veículo teve a maior velocidade média

Spark SQL - Hive

- **Cloudera**
- **sudo cp usr/lib/hive/conf/hive-site.xml /usr/lib/spark/conf/**
- **val hc = new org.apache.spark.sql.hive.HiveContext(sc)**
- **val hvdata = hc.sql (“ show databases”)**
- **val hvdata = hc.sql (“ show tables”)**
- Por padrão, todas as tabelas criadas pelo Spark SQL são tabelas gerenciadas pelo Hive, ou seja, o Hive tem controle completo sobre o ciclo de vida de uma tabela, incluindo a exclusão se os metadados da tabela forem eliminados usando o comando drop table. Isso vale apenas para tabelas persistentes.

Exercícios Hive

- Importar dados p/ HDFS
- Criar tabela no Hive
- Tratar os dados
  - Arquivo CID
  - Arquivo CSV de 10Gb

- CREATE DATABASE/SCHEMA, TABLE, VIEW, FUNCTION, INDEX
- DROP DATABASE/SCHEMA, TABLE, VIEW, INDEX
- TRUNCATE TABLE
- ALTER DATABASE/SCHEMA, TABLE, VIEW
- MSCK REPAIR TABLE (or ALTER TABLE RECOVER PARTITIONS)
- SHOW DATABASES/SCHEMAS, TABLES, TBLPROPERTIES, VIEWS, PARTITIONS, FUNCTIONS, INDEX[ES], COLUMNS, CREATE TABLE
- DESCRIBE DATABASE/SCHEMA, table_name, view_name

Hive

https://cwiki.apache.org/confluence/display/Hive/LanguageManual+DDL

Spark Streaming

- O Spark Streaming provê Api para processamento em tempo real de big data - ou seja, análise em tempo real -
- Latência muito baixa, normalmente alguns segundos.

- Streaming é o processo de dividir dados de entrada em fluxo contínuo em unidades discretas, que pode ser processado facilmente.
- Exemplos mais comuns são streaming de vídeo e áudio, dados de vendas, segurança etc
- A solução implementada é transferir dados em pequenos blocos que começam a ser reproduzidos para o usuário, enquanto o restante dos dados estão sendo baixados em segundo plano.
- A taxa na qual um aplicativo de streaming recebe dados é é expresso na forma de kilobytes por segundo (kbps) ou megabytes por segundo (mbps).

Spark Streaming

- import org.apache.spark.SparkConf
- import org.apache.spark.streaming.{Seconds,StreamingContext}
- import org.apache.spark.storage.StorageLevel
- import StorageLevel._
- import org.apache.spark._
- import org.apache.spark.streaming._
- import org.apache.spark.streaming.StreamingContext._

Spark Streaming

- val ssc = new StreamingContext(sc, Seconds(5))
- val lines = ssc.textFileStream("file:///C:/Dados/E5/")
- val wordsFlatMap = lines.flatMap(_.split(" "))
- val wordsMap = wordsFlatMap.map(w => (w,1))
- val wordCount = wordsMap.reduceByKey((a,b) => (a+b))
- wordCount.print
- ssc.start

Exercício Streaming

- Criar um aplicativo com uma funcionalidade diferente
- Ex:
  - Valores Máximos e Mínimos
  - Leitura de outros tipos de arquivos
  - Processo de Leitura do HDFS

Anaconda – Python

Anaconda – Python

- Prompt
  - C:\Projetos
  - Jupyter notebook
  - New – Python3
  - Sc – Pra Executar Shift+enter

  - C:\Spark\Projetos
  - Pyspark
  - Sc

Jupyter – Python

```
def quadrado(num):
    a = num**2
    return a
```

```
def quadrado(num):
    return num**2
```

```
def quadrado(num): return num**2
```

Jupyter

- Funções Lambda
  - Não recebem nome, Principal vantagem é um menor uso de memória

- Funções Lambda Booleana

Jupyter

- List
  - lista = [1,2,3,4,5,6,7,8,9,10]

```
lst = []

for i in lista:
    num = i ** 2
    lst.append(num)

print(lst)
```

  - [item ** 2 for item in lista]
  - [item for item in lista if item % 2 == 0]
  - [item ** 2 for item in lista if item % 2 == 0]

Jupyter - Map

- map() é uma função *builtin* de Python, isto é, uma função que é implementada diretamente no interpretador Python, podendo ser utilizada sem a importação de um módulo específico. Essa função, em Python, serve para **aplicar uma função a cada elemento de uma lista**, retornando uma nova lista contendo os elementos resultantes da aplicação da função

Jupyter - Map

- lista = [2,4,6,8,10]

```
def soma_dez(num):
    return num + 10
```

```
for elemento in lista:
    print(soma_dez(elemento))
```

- **lista_map = map(soma_dez, lista)**
- print(lista_map)
- print(list(lista_map))

Jupyter - Reduce

- reduce() é outra função *builtin* do Python (deixou de ser *builtin* e passou a estar disponível no módulo *functools* a partir da versão 3000). Sua utilidade está na aplicação de uma função a todos os valores do conjunto, de forma a **agregá-los todos em um único valor.** Por exemplo, para aplicar a operação de soma a todos os elementos de uma sequência, de forma que o resultado final seja a soma de todos esses elementos, poderíamos fazer o seguinte:

```
import operator
valores = [1, 2, 3, 4, 5]
soma = reduce(operator.add, valores)
print soma
```

Jupyter - Filter

- Como o próprio nome já deixa claro, filter() filtra os elementos de uma sequência. O processo de filtragem é definido a partir de uma função que o programador passa como primeiro argumento da função. Assim, filter() só "deixa passar" para a sequência resultante aqueles elementos para os quais a chamada da função que o usuário passou retornar True.

Jupyter - Filter

- lista = [1,2,3,4,5,6,7,8,9]
- print(lista)

```
def funpar(num):
    return num % 2 == 0
```

- funpar(500)

- Utilizando Filter, retorna apenas os verdadeiros
- list(filter(funpar, lista))

Jupyter - Filter

- Exemplo 2

```
filmes= ["1,The Nightmare Before Christmas,1993,3.9,4568",
         "2,The Mummy,1932,3.5,4388",
         "3,Orphans of the Storm,1993,2.8,6150",
         "4,The Object of Beauty,1991,2.8,6150"]
```

```
def cont_words(a):
    return a.count("1993") >= 1
```

- list(filter(cont_words, filmes))

Jupyter - WordCount

Exercício 4

- Contexto SQL Jupyter
  - Movies

Bibliografia

Muito Obrigado!!!

- evertoncesario@hotmail.com
- 41 99958-3361